

Previsão do Nível de Ocupação de Postos de Transformação de Distribuição com Técnicas de Aprendizagem Automática: Implicações para a Integração de Mobilidade Elétrica

1st Luna Gomes
dept. de Engenharia Informática
ISEP
Porto, Portugal
1231651@isep.ipp.pt

2nd Mariana Martins
dept. de Engenharia Informática
ISEP
Porto, Portugal
1230679@isep.ipp.pt

3rd Samara Miranda
dept. de Engenharia Informática
ISEP
Porto, Portugal
1230432@isep.ipp.pt

Abstract—Este artigo apresenta a segunda iteração de um estudo sobre a relação entre a eficiência energética da Iluminação Pública (IP) e a capacidade da rede de Postos de Transformação de Distribuição (PTD) em Portugal. Enquanto a primeira iteração se centrou numa análise estatística agregada ao nível do concelho, o presente trabalho desce ao nível do PTD individual (cerca de 69 000 registos), aplicando técnicas de Aprendizagem Automática para prever, por um lado, a folga de potência disponível em cada posto (P_{Folga_PTD} , problema de regressão) e, por outro, o nível de ocupação da rede ($utilizRede$, problema de classificação em três classes: baixo, médio e alto). Foram desenvolvidos e comparados modelos de regressão linear simples e múltipla, árvores de decisão/regressão, *Support Vector Machines* (SVM) e redes neuronais, e modelos de classificação por árvore de decisão, SVM, K-vizinhos-mais-próximos (KNN) e redes neuronais, todos avaliados por validação cruzada de 10 *folds*. Discute-se ainda o problema do desequilíbrio das classes da variável $utilizRede$ (51%/25%/24%), as suas causas estruturais e as estratégias de mitigação propostas, nomeadamente a técnica *Synthetic Minority Oversampling Technique* (SMOTE). Os resultados mostram que a Árvore de Decisão (profundidade 7) obtém o melhor desempenho global na classificação (Accuracy ≈ 0.699), estatisticamente equivalente ao da rede neuronal, e que a folga de rede ao nível do PTD é dominada pela variável Cap_PTD_kVA , enquanto a ocupação da rede é melhor explicada pela capacidade por cliente ($Cap_per_Cliente$). Conclui-se que o impacto da modernização LED na folga de rede ao nível do PTD individual é marginal, reforçando conclusões da primeira iteração do trabalho.

Index Terms—Aprendizagem Automática, Classificação, Regressão, Árvores de Decisão, SVM, KNN, Redes Neuronais, SMOTE, Postos de Transformação, Mobilidade Elétrica.

I. INTRODUÇÃO

A integração de infraestruturas de carregamento para veículos elétricos (VE) na rede de distribuição de baixa tensão depende criticamente da disponibilidade de capacidade nos Postos de Transformação de Distribuição (PTD). Na primeira iteração deste trabalho (TP1), realizou-se uma análise estatística exploratória ao nível do concelho, definindo um

conjunto de métricas de engenharia — Ganho LED (ΔP_{LED}), Folga de Rede (P_{Folga}), Carga VE (P_{VE}) e o Saldo Final de Viabilidade (D) — e ajustando um modelo de regressão linear múltipla para o nível médio de ocupação da rede. Esse modelo obteve um coeficiente de determinação ajustado de apenas $R_{adj}^2 = 6.4\%$, evidenciando que a agregação ao nível do concelho dilui a heterogeneidade real da rede e tem um poder explicativo limitado.

Esta segunda iteração (TP2) parte desta limitação para evoluir de uma análise agregada para uma análise ao nível do PTD individual, com aproximadamente 69 000 registos após pré-processamento. A granularidade adicional permite aplicar técnicas de Aprendizagem Automática (AA) estudadas ao longo do semestre — regressão linear/múltipla, árvores de decisão e de regressão, SVM, KNN e redes neuronais — tanto para prever variáveis contínuas (regressão) como para classificar o estado de ocupação da rede (classificação).

Definem-se dois problemas centrais. No problema de **regressão**, pretende-se prever a Folga de Rede por PTD (P_{Folga_PTD}), métrica que determina diretamente a capacidade de cada posto para absorver cargas de mobilidade elétrica. No problema de **classificação**, deriva-se da variável $Util_Decimal$ um atributo categórico $utilizRede$ com três níveis — *baixo*, *médio* e *alto* — e pretende-se prever esta classe a partir das características estruturais do PTD e do respetivo concelho.

Um desafio adicional identificado é o **desequilíbrio de classes** de $utilizRede$ (aproximadamente 51%/25%/24%), resultante da natureza discreta da variável $Util_Decimal$ subjacente (apenas 6 valores distintos). Este desequilíbrio penaliza sistematicamente a classe minoritária *médio*, e motiva a discussão de técnicas de *oversampling*, nomeadamente o SMOTE, como estratégia de mitigação.

II. OBJETIVOS

Os objetivos específicos deste trabalho são:

Identify applicable funding agency here. If none, delete this.

- **Análise Exploratória ao nível do PTD:** caracterizar a distribuição das variáveis estruturais (capacidade, número de clientes, tipo construtivo) e das variáveis derivadas (PFolga_PTD, Ganho_LED_PTD, Rate_Ineficiencia, LED_Ratio) ao nível individual do posto de transformação.
- **Pré-processamento e Seleção de Variáveis:** tratar valores omissos, codificar variáveis categóricas, padronizar variáveis numéricas e selecionar criteriosamente as *features* de modelação, evitando *data leakage*.
- **Modelação de Regressão:** desenvolver e comparar modelos de regressão linear simples, regressão linear múltipla, árvore de regressão, SVM e rede neuronal para prever PFolga_PTD, avaliados por validação cruzada de 10 *folds*.
- **Modelação de Classificação:** desenvolver e comparar modelos de árvore de decisão, SVM, KNN e rede neuronal para prever utilizRede, com particular atenção ao impacto do desequilíbrio de classes.
- **Análise Estatística Comparativa:** testar, com $\alpha = 0.05$, se as diferenças de desempenho entre os melhores modelos são estatisticamente significativas.
- **Discussão Crítica:** identificar limitações dos dados e dos modelos, e propor estratégias de melhoria, incluindo SMOTE, *ensemble learning* e estratificação urbano/rural.

III. ESTADO DA ARTE

A literatura sobre aprendizagem automática aplicada a redes elétricas inteligentes (*smart grids*) tem-se concentrado sobretudo em problemas de previsão de carga, deteção de anomalias e planeamento de infraestrutura de carregamento de VE. Modelos baseados em árvores de decisão e os seus *ensembles* (Random Forest, Gradient Boosting) destacam-se pela sua interpretabilidade e robustez face a *features* heterogéneas e com diferentes escalas [1]. Os SVM, com *kernels* não-lineares como o *Radial Basis Function* (RBF), são adequados quando as fronteiras entre classes não são linearmente separáveis, mas têm custo computacional elevado em *datasets* de grande dimensão [1], [2]. O algoritmo KNN, apesar da sua simplicidade conceptual, é sensível à escolha do parâmetro K e à escala das variáveis, exigindo padronização prévia [2].

No que respeita a redes neuronais, a literatura recomenda a aplicação de técnicas de regularização (*dropout*, penalização L_2) e de *early stopping* para mitigar o sobreajuste (*overfitting*), especialmente em problemas com um número limitado de *features* informativas [1]. A escolha da *learning rate* é determinante para a estabilidade da convergência: valores demasiado elevados provocam oscilações (*overshooting*), enquanto valores demasiado baixos atrasam a convergência ou prendem o modelo em mínimos locais [1].

Relativamente ao desequilíbrio de classes, um problema recorrente em *datasets* de infraestrutura elétrica (onde estados de operação normal são tipicamente mais frequentes do que estados de risco), a técnica SMOTE [1], [3] é amplamente referida como estratégia de *oversampling*, gerando exemplos sintéticos da(s) classe(s) minoritária(s) por interpolação entre

vizinhos próximos no espaço de *features*, em alternativa ao simples *undersampling* da classe majoritária ou ao uso de pesos de classe (*class_weight*). Métricas *weighted* de *precision*, *recall* e *F1-score*, bem como a validação cruzada de *k-folds*, são práticas-padrão para uma avaliação robusta de modelos em cenários de desequilíbrio [1]–[3].

IV. METODOLOGIA E DADOS

A análise segue as etapas de carregamento, exploração, pré-processamento, modelação e avaliação estatística, recorrendo às bibliotecas Python Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn, SciPy, Statsmodels e TensorFlow/Keras. Todos os testes de hipótese foram realizados com nível de significância $\alpha = 0.05$, e a reprodutibilidade foi garantida através de uma *seed* fixa (SEED = 42) em todas as operações estocásticas (amostragem, divisão de *folds*, inicialização de redes neuronais).

A. Dataset e Continuidade com o TPI

O *dataset* utilizado, PTD_level_dataset.xlsx, resulta da junção dos ficheiros IP_data.xlsx e PTD_data.xlsx através da variável CodDistritoConcelho, associando a cada PTD as características agregadas do respetivo concelho. O *dataset* contém aproximadamente 72 000 registos, dos quais $\approx 4.3\%$ foram removidos por ausência de nível de utilização, resultando em $\approx 69 000$ PTDs para modelação.

As variáveis críticas definidas na primeira iteração foram recalculadas ao nível do PTD individual e validadas contra as fórmulas do TPI:

$$PFolga_PTD = Cap_PTD_kVA \times 0.92 \times (1 - Util_Decimal) \quad (1)$$

$$PVE_PTD = 22 \times 0.60 = 13.2 \text{ kVA (constante)} \quad (2)$$

$$D_PTD = PFolga_PTD - PVE_PTD \quad (3)$$

$$D_PTD_LED = PFolga_PTD + Ganho_LED_PTD - PVE_PTD \quad (4)$$

B. Análise Exploratória e Decisões de Pré-processamento

A análise das distribuições por gráficos de densidade (KDE) revelou assimetria positiva acentuada em Cap_PTD_kVA, N_Clientes, PFolga_PTD, D_PTD e Ganho_LED_PTD, refletindo a coexistência de um grande número de PTDs de pequena dimensão com uma cauda longa de PTDs urbanos de grande capacidade. A variável LED_Ratio apresenta uma distribuição **bimodal** (picos próximos de 0 e de 1), evidenciando que a transição tecnológica é tipicamente realizada de forma massiva por projeto municipal, sem fases intermédias generalizadas. A variável Util_Decimal é **multimodal e discreta**, com picos em 0.19, 0.39, 0.59, 0.79, 0.99 e 1.00 — o pico mais elevado em 0.79 indica que uma fração substancial dos PTDs opera próxima da sua capacidade nominal, reforçando a motivação do trabalho.

A Tabela I sintetiza as decisões de pré-processamento e respetivas justificações.




Fig. 1: Distribuição Bimodal da modernização (a) e da Ocupação dos PTDs (b), justificando a discretização em três classes.




Fig. 2: Identificação de *outliers* e dispersão dos dados nas variáveis principais da infraestrutura.

Após estas exclusões, resultou um conjunto de 16 *features* para modelação, incluindo variáveis estruturais do PTD (Cap_PTD_kVA, N_Clientes, Pot_Contratada_kVA, Cap_per_Cliente, PContratada_per_Cliente, Tipo_Construtivo_enc), variáveis de iluminação pública agregadas ao concelho (P_IP_Total, Rate_Ineficiencia, LED_Ratio, Ganho_LED_PTD, IP_Inef_per_PTD, N_Luminarias, N_Lampadas) e a escala geográfica (N_PTDs_Concelho). Foram mantidas duas versões do conjunto de *features*: X em escala original, utilizada nos modelos baseados em árvores (invariantes à escala), e X_{sc} , padronizada via *StandardScaler*, utilizada

TABLE I: Decisões de Pré-processamento

Variável(eis)	Decisão	Justificação
Identificadores, coordenadas, Potência instalada [kVA]	Excluídas	Sem poder preditivo; redundantes com Cap_PTD_kVA
Nível de Utilização [%] (texto)	Excluída	Redundante com Util_Decimal (numérica)
Pot_Geracao_kW e derivadas	Excluídas	≈97.5% de valores omissos
Distrito, Concelho, CodDistritoConcelho	Excluídas	Escala geográfica capturada por N_PTDs_Concelho
Pot_Contratada_kVA Imputação	Excluída	Mediana por Tipo Construtivo
PContratada_per_Cliente (≈29% nulos)	Excluída	Mediana por Tipo Construtivo
Util_Decimal, D_PTD, D_PTD_LED	Excluídas	<i>Data leakage</i> : derivadas diretas do(s) <i>target(s)</i>
PVE_PTD	Excluída	Constante (13.2 kVA), variância nula
Tipo Construtivo	Codificação	<i>Label encoding</i> (Tipo_Construtivo_enc)

em SVM, KNN e redes neurais.

A análise de correlação com PFolga_PTD confirmou Cap_PTD_kVA como a variável dominante ($r = 0.92$), seguida de Cap_per_Cliente ($r = 0.60$) e Tipo_Construtivo_enc ($r = 0.52$). As variáveis de iluminação pública apresentam correlações fracas (entre 0.08 e 0.39), confirmando quantitativamente que o impacto da transição LED na folga de rede ao nível do PTD individual é marginal. Identificaram-se ainda *clusters* de elevada multicolinearidade: N_Luminarias/N_Lampadas/N_PTDs_Concelho ($r \approx 0.95$ entre si) e IP_Inef_per_PTD/Ganho_LED_PTD ($r = 1.00$), relevantes para a interpretação dos coeficientes da regressão linear múltipla.

C. Variável de Classificação: utilizRede

A variável *utilizRede* foi derivada de Util_Decimal com base em **intervalos fixos com significado operacional** (Tabela II), em alternativa a uma discretização por quantis (*pd.qcut*). Esta opção justifica-se porque Util_Decimal é uma variável discreta com apenas 6 valores distintos, dos quais o valor 0.39 representa ≈30% do *dataset* (20 892 PTDs) — qualquer divisão por quantis seria inviável de equilibrar, uma vez que todos os PTDs com esse valor pertenceriam obrigatoriamente à mesma classe.

TABLE II: Definição da Variável *utilizRede*

Classe	Intervalo	Significado
baixo	$Util_Decimal \leq 0.50$	Folga confortável
médio	$0.50 < Util_Decimal \leq 0.75$	Zona de atenção
alto	$Util_Decimal > 0.75$	Próximo dos limites

A distribuição resultante é **desequilibrada** (baixo ≈51%, médio ≈25%, alto ≈24%), consequência direta da natureza discreta dos dados subjacentes e não de uma escolha metodológica arbitrária. Este desequilíbrio é discutido em detalhe na Secção VI, incluindo o seu impacto nas métricas *por classe* e a proposta de mitigação via SMOTE.

D. Validação Cruzada e Métricas de Avaliação

Todos os modelos foram avaliados por validação cruzada de 10 *folds* (*KFold*, *shuffle=True*, *random_state=SEED*), com o mesmo objeto *KFold* partilhado entre modelos para garantir *folds* idênticos e viabilizar testes estatísticos pareados. Para a regressão, reportam-se o erro médio absoluto (MAE) e a raiz do erro médio quadrático (RMSE), em valor médio ± desvio padrão sobre os 10 *folds*. Para a classificação, reportam-se *Accuracy*, *Precision*, *Recall* e *F1-score*, calculados com a agregação *weighted* (ponderação por frequência de classe), adequada ao cenário *desequilibrado*, com *zero_division=0* para evitar erros em *folds* onde uma classe minoritária não recebe previsões.

E. Parametrização dos Modelos de Regressão

Para a previsão de PFolga_PTD, foram desenvolvidos os seguintes modelos:

- **Regressão Linear Simples:** utilizando a variável explicativa com maior correlação absoluta com o *target* (Cap_PTD_kVA, $r = 0.9159$), excluindo PVE_PTD (constante).
- **Regressão Linear Múltipla:** utilizando o conjunto completo de 16 *features* padronizadas (X_{sc}).
- **Árvore de Regressão:** profundidade (*max_depth*) otimizada por busca em grelha sobre {3, 5, 7, 10, 15, None}, selecionando o valor que minimiza o MAE médio nos 10 *folds*.
- **SVM (SVR):** dado o custo computacional $O(n^2)$ – $O(n^3)$, treinado num subconjunto aleatório de $n = 6\,000$ registos (8.7% do *dataset*, *seed* fixa). Foram comparados os *kernels* linear, rbf e poly com $C = 1.0$ fixo.
- **Rede Neuronal:** avaliada por 10-fold CV, com reconstrução completa da rede em cada *fold*. Foram testadas três configurações (Tabela III), variando profundidade, largura, regularização e *learning rate*, com *early stopping* (*patience*=20) baseado na *val_loss*.

TABLE III: Configurações da Rede Neuronal — Regressão

Config	Camadas	Neurónios	Regulariz.	LR
Shallow	2	[64, 32]	Nenhuma	10^{-3}
Medium	3	[128, 64, 32]	Dropout 20%	10^{-3}
Deep+L2	4	[256, 128, 64, 32]	Dropout 30% + L_2 (10^{-4})	5×10^{-4}

O valor de *patience*=20 foi adotado após observar que *patience*=10 interrompia prematuramente o treino das configurações com *dropout*/ L_2 , antes da convergência genuína, devido a oscilações na *val_loss* induzidas pela regularização. A *learning rate* da configuração Deep+L2 foi reduzida para 5×10^{-4} , dado que redes mais profundas com L_2 apresentam superfícies de perda mais complexas, beneficiando de passos de gradiente menores.

F. Parametrização dos Modelos de Classificação

Para a previsão de *utilizRede*, foram desenvolvidos os seguintes modelos, todos avaliados com o mesmo objeto *KFold* de 10 *folds*:

- **Árvore de Decisão:** *max_depth* otimizado por busca manual sobre {3, 5, 7, 10, 15, None}, selecionando o valor que maximiza a *Accuracy* média. A configuração None (profundidade ilimitada) serve como referência de sobreajuste.
- **SVM (SVC):** dado o custo computacional, treinado num subconjunto aleatório de $n = 10\,000$ registos (14.5% do *dataset*, *seed* fixa). Foram comparados os *kernels* linear, rbf e poly com $C = 1.0$ fixo, sobre X_{sc} (*features* padronizadas, obrigatórias dada a sensibilidade do SVM à escala).
- **KNN:** o parâmetro K foi otimizado por busca manual sobre {1, 3, 5, 7, 10, 15, 20, 30, 50}, sobre X_{sc} (distâncias euclidianas exigem padronização prévia, dado que Cap_PTD_kVA é medida em centenas de kVA enquanto LED_Ratio varia entre 0 e 1).
- **Rede Neuronal:** avaliada por 10-fold CV com reconstrução por *fold*. O *target* categórico foi convertido

para inteiros via *LabelEncoder* e depois para *one-hot encoding* via *to_categorical*, compatível com a função de perda *categorical_crossentropy* e ativação *softmax* na camada de saída. Foram testadas três configurações análogas às da Tabela III (Shallow [64,32]/*dropout* 20%/LR 10^{-3} ; Medium [128,64,32]/*dropout* 20%/LR 10^{-3} ; Deep [256,128,64,32]/*dropout* 30%/LR 5×10^{-4}), com *patience*=20.

G. Tratamento do Desequilíbrio de Classes e SMOTE

O desequilíbrio de *utilizRede* (51%/25%/24%) foi tratado, na presente iteração, através do uso de métricas *weighted* (que ponderam cada classe pela sua frequência) em todas as comparações de modelos, evitando que o desempenho na classe majoritária *baixo* mascare um fraco desempenho nas classes *médio* e *alto*. A técnica **SMOTE** (*Synthetic Minority Oversampling Technique*), que gera exemplos sintéticos das classes minoritárias por interpolação no espaço de *features* entre vizinhos próximos, foi identificada como a estratégia de mitigação mais diretamente aplicável ao problema, dado que ataca a causa imediata do baixo *recall* observado na classe *médio* (Secção VI). A aplicação de SMOTE ao conjunto de treino de cada *fold* (evitando contaminação do conjunto de validação com amostras sintéticas) constitui a principal recomendação de trabalho futuro decorrente da análise de resultados.

V. RESULTADOS E DISCUSSÃO

Esta secção apresenta e discute os resultados obtidos pelos quatro modelos de classificação desenvolvidos para prever a variável *utilizRede* (*baixo*, *médio*, *alto*), avaliados por validação cruzada de 10 *folds* com o mesmo objeto *KFold* partilhado.

A. Resultados da Regressão para Folga de Rede (PFolga_PTD)

A previsão da variável contínua *PFolga_PTD* revelou comportamentos muito distintos entre os modelos. A Regressão Linear Simples, baseada unicamente na capacidade instalada (Cap_PTD_kVA), alcançou um R^2 de 0.83. Contudo, ao expandir para um modelo de Regressão Múltipla com as 16 *features*, não se verificaram ganhos substanciais de desempenho.

A Árvore de Regressão provou ser o modelo mais eficaz, minimizando o erro (MAE) sem assumir pressupostos lineares estritos que, neste **dataset**, foram violados pelas caudas longas da distribuição. As Redes Neurais, apesar das regularizações, apresentaram dificuldades em estabilizar o erro quadrático para os **outliers** de alta capacidade.

Para analisar a eficiência do treino na regressão, avaliaram-se as curvas de aprendizagem. A Fig. 3 ilustra as curvas da Árvore de Regressão otimizada. Nota-se que o erro de treino permanece baixo, enquanto a curva de validação estabiliza em torno das 4000 amostras, não revelando sinais de *overfitting* severo graças ao controlo da profundidade da árvore.




Fig. 3: Curvas de Aprendizagem para o modelo de Árvore de Regressão. A estabilização do erro de validação (MSE) indica uma parametrização adequada face ao volume de dados de treino.

B. Comparação Global dos Modelos

A Tabela IV sintetiza as métricas globais (*weighted*) obtidas pelos quatro classificadores. Todos os resultados são expressos como média $\pm$ desvio padrão sobre os 10 *folds*.

TABLE IV: Desempenho Global dos Modelos de Classificação (10-fold CV, métricas *weighted*)

Modelo	Acc.	Prec.	Rec.	F1
SVM (RBF)	0.6903 $\pm$.010	0.6704 $\pm$.009	0.6903 $\pm$.010	0.6668 $\pm$.012
Árvore ($d = 7$)	0.6884 $\pm$.011	0.6740 $\pm$.014	0.6884 $\pm$.011	0.6773 $\pm$.014
KNN ($k = 20$)	0.6446 $\pm$.010	0.6163 $\pm$.012	0.6446 $\pm$.010	0.6180 $\pm$.012
NN (Config2)	0.6217 $\pm$.020	0.5888 $\pm$.025	0.6217 $\pm$.020	0.5498 $\pm$.031

O SVM com *kernel* RBF obtém a melhor *Accuracy* (0.6903 $\pm$ 0.010), enquanto a Árvore de Decisão com profundidade 7 apresenta o melhor F1 ponderado (0.6773) e a maior estabilidade entre os dois modelos top. O KNN fica em terceiro lugar (0.6446), e a Rede Neuronal apresenta o desempenho mais baixo (0.6217), reflexo da restrição ao subconjunto de 15 000 registos, que penaliza as redes neurais de forma desproporcional relativamente aos outros modelos.

O parâmetro K do KNN foi otimizado por busca manual sobre $\{1, 3, 5, 7, 10, 15, 20, 30, 50\}$; o valor ótimo $K = 20$ equilibra o tradeoff viés-variância típico do algoritmo (Fig. 4). Para $K = 1$, a *Accuracy* desce para 0.5615, evidenciando o *overfitting* clássico de um único vizinho; a partir de $K = 20$ observa-se uma ligeira descida, confirmando introdução de viés por vizinhos excessivamente distantes.




Fig. 4: Otimização do hiperparâmetro K no KNN. O valor ótimo $K = 20$ maximiza a *Accuracy* média nos 10 *folds*; valores superiores introduzem viés progressivo.

C. Teste Estatístico entre os Dois Melhores Modelos

A diferença de *Accuracy* entre o SVM (RBF) e a Árvore ($d = 7$) é de apenas 0.0019 pontos percentuais, motivando um teste estatístico pareado. A distribuição das diferenças entre os 10 *folds* foi testada por Shapiro-Wilk ($p = 0.342$), aceitando-se a normalidade e aplicando-se o *t-test* pareado:

$$t = 0.698, \quad p = 0.503$$

Com $p > 0.05$, não existe diferença estatisticamente significativa entre os dois modelos ao nível de confiança de 95%. A aparente superioridade do SVM em *Accuracy* é atribuível à variabilidade natural entre *folds*. A escolha recai na **Árvore de Decisão** ($d = 7$) por critérios secundários: melhor F1 global (0.6773 vs. 0.6668), melhor *Recall* na classe *médio* (0.39 vs. 0.30) e total interpretabilidade através das regras da árvore e das importâncias das variáveis, aspetos operacionalmente determinantes num contexto de planeamento de rede.

D. Análise por Classe – Matriz de Confusão

A Tabela V detalha as métricas por classe para os quatro modelos (*cross_val_predict* 10-fold para os modelos sklearn; *split* 80/20 representativo para a NN, por incompatibilidade do Keras com *cross_val_predict*).

TABLE V: Métricas por Classe – Todos os Modelos

Modelo	Classe	Prec.	Rec.	F1
Árvore ($d = 7$)	<i>baixo</i>	0.76	0.86	0.80
	<i>alto</i>	0.69	0.63	0.66
	<i>médio</i>	0.48	0.39	0.43
SVM (RBF)	<i>baixo</i>	0.72	0.90	0.80
	<i>alto</i>	0.70	0.64	0.67
	<i>médio</i>	0.53	0.30	0.39
KNN ($k = 20$)	<i>baixo</i>	0.70	0.88	0.78
	<i>alto</i>	0.60	0.57	0.58
	<i>médio</i>	0.45	0.25	0.32
NN (Config2)	<i>baixo</i>	0.76	0.88	0.82
	<i>alto</i>	0.71	0.63	0.67
	<i>médio</i>	0.51	0.39	0.44

Emerge um padrão consistente em todos os modelos: a classe *baixo* é sistematicamente a mais fácil de classificar (*Recall* entre 0.86 e 0.90), seguida de *alto* (*Recall* entre 0.57 e 0.64), e a classe *médio* apresenta o desempenho mais baixo em todos os classificadores (*Recall* entre 0.25 e 0.39).

Classe *baixo* – A maioria dos PTDs nesta categoria é corretamente identificada porque esta é a classe maioritária (51%), proporcionando um número superior de exemplos de treino. O elevado *Recall* (> 0.86) indica que quase todos os PTDs com folga confortável são devidamente assinalados.

Classe *médio* – Principal ponto fraco – Esta classe ($\approx 25\%$) situa-se no intervalo $[0.50, 0.75]$ de *Util_Decimal* e partilha características com as classes adjacentes. A matriz de confusão da Árvore (Fig. 5) evidencia o problema: dos

3 732 PTDs *médio*, apenas 1 471 são corretamente classificados, e 1 473 são erroneamente atribuídos à classe *baixo*. Isto traduz-se, numa aplicação operacional, em PTDs em “zona de atenção” incorretamente sinalizados como aptos para receber carregadores de VE. O baixo desempenho nesta classe resulta diretamente da natureza discreta de *Util_Decimal*, que apenas assume 6 valores distintos, tornando as fronteiras entre classes artificialmente difusas.

Classe alto – Os modelos tendem a ser conservadores na atribuição desta categoria, com *Precision* > *Recall* em todos os casos. Os 637 PTDs *alto* mal classificados como *baixo* pela Árvore representam o **risco operacional mais grave**: PTDs próximos do limite são identificados como tendo folga adequada para VE.




Fig. 5: Matriz de Confusão da Árvore de Decisão ($d = 7$), obtida por *cross_val_predict* com 10 *folds*. A classe *médio* acumula o maior número de erros, com 1 473 PTDs erroneamente atribuídos à classe *baixo*.

E. Importância das Variáveis

A Fig. 6 apresenta o *Gini importance* extraído da Árvore de Decisão ($d = 7$). A variável *Cap_per_Cliente* domina de forma esmagadora, concentrando **70%** da importância total. A variável *PContratada_per_Cliente* contribui com cerca de 19%, e as restantes 14 features – incluindo *N_Clientes* (2.8%), *Cap_PTD_kVA* (2.8%) e *Pot_Contratada_kVA* (2.5%) – somam menos de 11% em conjunto.

Destaca-se um resultado contra-intuitivo face à análise de correlação: na regressão, *Cap_PTD_kVA* era a variável dominante ($r = 0.92$ com *PFolga_PTD*), mas na classificação a sua importância é residual ($\approx 2.8\%$). Esta inversão explica-se pela natureza das tarefas: ao prever a **folga absoluta**, a capacidade total do PTD é o fator determinante; ao prever o **nível relativo de ocupação** da rede, o que discrimina as classes é a capacidade *por cliente* – quanto maior a capacidade por cliente, menor a probabilidade de o PTD estar sobrecarregado.

Todas as variáveis de Iluminação Pública (*Rate_Ineficiencia*, *Ganho_LED_PTD*, *LED_Ratio*, *P_IP_Total*, entre outras) apresentam importância prática




Fig. 6: Importância das variáveis na Árvore de Decisão (*Gini impurity*). *Cap_per_Cliente* e *PContratada_per_Cliente* concentram $\approx 89\%$ da importância total; todas as variáveis de Iluminação Pública apresentam contributo residual.

nula na classificação. Este resultado é consistente com a sua agregação ao nível do concelho: distribuir os mesmos indicadores municipais pelos ≈ 377 PTDs medianos de cada município introduz variabilidade artificial e dilui o poder discriminativo real destas variáveis, tornando-as inoperantes para a classificação ao nível individual do PTD.

F. Curvas de Aprendizagem

As curvas de aprendizagem para os modelos sklearn (Fig. 7) comparam o melhor (SVM RBF, *Accuracy* = 0.6903) e o pior (KNN $k = 20$, *Accuracy* = 0.6446) classificador sklearn. A NN é excluída desta análise por incompatibilidade entre Keras e *learning_curve* do sklearn.




Fig. 7: Curvas de Aprendizagem dos modelos SVM (RBF) e KNN ($k = 20$). O SVM mostra conversão eficiente sem *over-fitting* persistente; o KNN atinge plateau prematuro e mantém gap treino/validação estável, indicando limitação estrutural do algoritmo.

SVM (RBF) – Diagnóstico de treino eficiente: a curva de treino inicia em ≈ 0.84 com 4 500 amostras, descendo para ≈ 0.70 com 12 000 amostras – indicação de que o modelo deixa de memorizar e generaliza. A curva de validação ascende monotonamente de ≈ 0.58 para ≈ 0.69 , sem oscilações. O gap final é residual (≈ 0.015), e a curva de validação ainda não atingiu *plateau*, sugerindo que o dataset completo ($\approx 69\,000$

registos) poderia proporcionar ganhos adicionais de 1 a 3 pontos percentuais.

KNN ($k = 20$) – Diagnóstico de *overfitting* inicial e *underfitting* persistente: a curva de treino parte de ≈ 1.0 com poucas amostras (comportamento clássico do KNN quando o ponto de consulta é o próprio vizinho mais próximo), descendo para ≈ 0.69 . A curva de validação ascende rapidamente mas atinge *plateau* precoce (≈ 0.64) por volta das 7000 amostras, sem ganhos adicionais com mais dados. O *gap* final estável (≈ 0.05) indica limitação estrutural do algoritmo: o KNN já extraiu toda a informação que consegue das features disponíveis.

As curvas de *loss* obtidas durante o treino da NN (em cada *fold* do CV) não evidenciam sinais de *overfitting* (a *val_loss* não cresce em nenhuma das três configurações), confirmando que os mecanismos de regularização (*dropout* e L_2) e o *early stopping* com *patience* = 20 contribuíram para uma convergência estável.

A eficiência do treino das redes neurais pode ser adicionalmente confirmada pela análise das curvas de entropia cruzada (*Cross-Entropy Loss*) por época (Fig. 8). A ausência de divergência entre a perda de treino e a perda de validação comprova que a arquitetura escolhida foi capaz de extrair os padrões representativos sem memorizar o ruído inerente aos *outliers* urbanos.




Fig. 8: Curva de Perda (Loss) do treino da Rede Neuronal para classificação ao longo das épocas, evidenciando uma convergência suave propiciada pelas técnicas de regularização.

As Árvores de Decisão com profundidade ilimitada (*max_depth* = None), testadas durante a otimização em grelha, apresentaram o padrão clássico de *overfitting* severo: *Accuracy* de treino de 1.0 e queda acentuada na validação, confirmando que a poda da profundidade máxima é indispensável neste contexto.

VI. LIMITAÇÕES E TRABALHO FUTURO

A. Limitações

Variável target com baixa resolução. A variável *Util_Decimal* assume apenas 6 valores distintos (0.19, 0.39, 0.59, 0.79, 0.99, 1.00), reflexo de um arredondamento de percentagens inteiras nos dados originais da e-REDES. Esta restrição impede uma discretização equilibrada em classes: qualquer divisão em três grupos resulta num desequilíbrio estrutural ($\approx 51\%$ / 25% / 24% para *baixo/médio/alto*), que penaliza sistematicamente a classe *médio* – com *Recall* de apenas 0.25 a 0.39 em todos os modelos.

Variáveis de Iluminação Pública agregadas ao nível do concelho. Atribuir os mesmos indicadores municipais (*Rate_Ineficiencia*, *Ganho_LED_PTD*, *LED_Ratio*)

a todos os ≈ 377 PTDs medianos de um município introduz variabilidade artificial e anula o poder discriminativo real destas variáveis ao nível do PTD individual. A importância nula destas features na Árvore confirma esta limitação.

Impacto marginal do LED ao nível do PTD individual. O ganho mediano de potência resultante da transição para LED é de apenas ≈ 0.32 kVA por PTD, negligenciável face à folga mediana de ≈ 77 kVA. Consequentemente, apenas 1 PTD muda de inviável para viável com LED no *dataset* completo, comprometendo o objetivo original de avaliar a sinergia entre eficiência na IP e mobilidade elétrica.

Modelos treinados num subconjunto de 15 000 registos. Por opção metodológica para acelerar o desenvolvimento e *tuning*, todos os modelos foram treinados em $\approx 22\%$ do *dataset* completo. As curvas de aprendizagem indicam que o SVM (RBF) ainda não atingiu *plateau* no fim do eixo do subconjunto, sugerindo ganho potencial com o *dataset* completo.

Ausência de dados de geração distribuída. A variável *Pot_Geracao_kW* apresenta $\approx 97.5\%$ de valores omissos e foi excluída. Com a expansão acelerada do solar fotovoltaico em Portugal, esta variável será progressivamente mais relevante para a previsão da folga de rede.

Heterogeneidade urbano-rural não modelada. Um modelo global treinado sobre todos os PTDs portugueses não captura as assimetrias estruturais entre contextos urbanos (alta densidade, perfis de consumo mais elevados) e rurais (menor carga, tipologias construtivas distintas).

B. Trabalho Futuro

Com base nas limitações identificadas, propõe-se um plano de melhorias ordenado por impacto esperado.

SMOTE para equilíbrio de classes. A aplicação de *Synthetic Minority Oversampling Technique* [6] ao conjunto de treino de cada *fold* – gerando amostras sintéticas das classes *médio* e *alto* por interpolação entre vizinhos no espaço de *features* – constitui a prioridade máxima, por endereçar diretamente o *Recall* catastrófico de 0.25 a 0.39 na classe *médio*.

Modelos ensemble avançados. A substituição da Árvore de Decisão simples por *ensemble* como *Random Forest* [7] ou XGBoost combina múltiplas árvores por *bagging* ou *boosting*, tipicamente obtendo ganhos de 5 a 10 pontos percentuais em *Accuracy* com melhor robustez ao desequilíbrio de classes.

Otimização mais granular de hiperparâmetros. A grelha atual testou um único hiperparâmetro por modelo. Alargar a pesquisa a C e γ no SVM, ao critério (*gini* vs. *entropy*) na Árvore e ao esquema de ponderação (*uniform* vs. *distance*) no KNN, por *loop* manual coerente com a metodologia adotada, poderia proporcionar melhorias adicionais modestas.

Estratificação dos modelos por tipologia de PTD. Treinar modelos separados por *Tipo_Construtivo* (ou por distinção urbano/rural) permitiria capturar assimetrias estruturais que um modelo global não consegue representar adequadamente.

Dados georreferenciados de IP. Substituir a agregação por concelho por uma alocação geográfica precisa do ganho LED a cada PTD – com base na proximidade entre luminárias e transformadores – reintroduziria as variáveis de IP como preditores efectivos, testando de forma mais rigorosa a hipótese central do trabalho.

VII. CONCLUSÃO

Este trabalho completou a transição metodológica iniciada no TP1 – de uma análise de regressão linear agregada ao nível do concelho ($R^2_{adj} = 6.4\%$) para uma modelação bívica ao nível do PTD individual ($\approx 69\,000$ registos) – abordando simultaneamente um problema de **regressão** (prever a folga de potência disponível `PFolga_PTD`) e um problema de **classificação** (prever o nível de ocupação da rede `utilizRede`), com o objetivo final de suportar decisões de integração de infraestrutura de carregamento de veículos eléctricos.

No problema de regressão, a Rede Neuronal Shallow emergiu como o modelo mais preciso ($MAE = 32.05 \pm 0.81$ kVA, $RMSE = 52.13$ kVA em 10-fold CV), confirmada como estatisticamente superior ao SVM linear ($MAE = 33.22$, $p < 0.05$, *t-test* pareado). A Regressão Linear Simples, baseada unicamente em `Cap_PTD_kVA` ($r = 0.92$), estabeleceu a *baseline* com $MAE \approx 51$ kVA, evidenciando que a capacidade instalada do transformador é o fator estrutural dominante da folga de rede. A Árvore de Regressão ($MAE = 34.18$, $d = 7$) revelou robustez face aos *outliers* de PTDs urbanos de grande porte – que violam os pressupostos de homoscedasticidade da regressão linear – sem recorrer a transformações do *target*. O MAE residual de ≈ 32 kVA na melhor configuração reflete o teto informativo atual das *features* disponíveis: a forte assimetria positiva da distribuição de `PFolga_PTD` e a ausência de dados de geração distribuída limitam a precisão absoluta independentemente do algoritmo adotado.

No problema de classificação, a **Árvore de Decisão com profundidade 7** constitui o modelo mais adequado ao contexto operacional, apesar de o SVM (RBF) registar *Accuracy* marginalmente superior (0.6903 vs. 0.6884). O teste *t* pareado ($t = 0.698$, $p = 0.503$, $\alpha = 0.05$) confirma que esta vantagem não é estatisticamente significativa. Os critérios secundários pendem inequivocamente para a Árvore: melhor F1 ponderado (0.6773 vs. 0.6668), melhor *Recall* na classe *médio* (0.39 vs. 0.30) e interpretabilidade direta através das regras de decisão e das importâncias Gini – atributos indispensáveis numa aplicação de planeamento de infraestrutura regulada.

O **calcanhar de Aquiles** de todos os classificadores é a classe *médio*: nenhum modelo ultrapassa $Recall = 0.39$, e a matriz de confusão da Árvore revela que 1 473 dos 3 732 PTDs *médio* são erroneamente sinalizados como *baixo*. Numa aplicação operacional, estes falsos positivos traduzem-se em PTDs em “zona de atenção” incorretamente identificados como aptos para receber carregadores de VE – o risco operacional mais relevante do classificador. A causa-raiz é estrutural: `Util_Decimal` assume apenas 6 valores distintos, tornando as fronteiras de decisão artificialmente difusas e

produzindo o desequilíbrio intrínseco de $\approx 51/25/24\%$ que penaliza sistematicamente a classe intermediária.

A análise de importância de *features* confirma, de forma taxativa, que o verdadeiro determinante da ocupação da rede é a **capacidade por cliente** (`Cap_per_Cliente`, 70% da importância Gini), complementada pela potência contratada por cliente (`PContratada_per_Cliente`, $\approx 19\%$). Em contraste, todas as variáveis de Iluminação Pública apresentam importância Gini prática nula: o ganho mediano da transição LED por PTD (≈ 0.32 kVA) é negligenciável face à folga mediana de ≈ 77 kVA, alterando o estado de viabilidade de apenas 1 PTD em todo o *dataset*. Esta conclusão, que aprofunda e corrobora o resultado do TP1, impõe uma reorientação estratégica: a modernização LED é politicamente relevante no plano da sustentabilidade energética global, mas insuficiente, por si só, para criar folga de rede mensurável ao nível do PTD individual que suporte a carga de um carregador típico de 22 kW.

Os modelos aqui desenvolvidos constituem, em conjunto, um sistema de apoio à decisão tecnicamente fundamentado para Operadores de Rede de Distribuição como a e-REDES: a regressão quantifica a folga disponível em cada PTD, e a classificação prioriza os postos candidatos à instalação de infraestrutura de carregamento. A sua maturidade operacional plena depende, contudo, de dois passos futuros prioritários – a aplicação de SMOTE ao conjunto de treino de cada *fold* para corrigir o *Recall* catastrófico na classe *médio*, e a recuperação dos valores contínuos de `Util_Decimal` em colaboração com a e-REDES – sem os quais qualquer classificador enfrenta um limite estrutural intransponível que compromete a fiabilidade das recomendações para o planeamento da mobilidade elétrica em Portugal.

AGRADECIMENTOS

Este trabalho foi desenvolvido com o apoio de ferramentas de Inteligência Artificial Generativa para apoio à programação, análise de dados e revisão textual. A utilização destas ferramentas foi efetuada de forma ética e transparente, mantendo sempre a validação crítica dos resultados pelos autores e respeitando as orientações institucionais relativas ao uso de IA em contexto académico.

REFERENCES

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] T. M. Mitchell, *Machine Learning*. McGraw-Hill, 1997.
- [3] G. James, D. Witten, T. Hastie and R. Tibshirani, *An Introduction to Statistical Learning*, 2nd ed., Springer, 2021.
- [4] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter*, 3rd ed., O'Reilly Media, 2022.
- [5] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*. MIT Press, 2016.
- [6] N. V. Chawla, K. W. Bowyer, L. O. Hall and W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [7] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [8] e-REDES, “Portal de Dados Abertos,” [Online]. Available: <https://www.e-redes.pt>