

Previsão do Nível de Utilização da Rede Elétrica de Distribuição através de Técnicas de Aprendizagem Automática

1st Luna Gomes
Departamento de Engenharia Informática
ISEP
Porto, Portugal
1231651@isep.ipp.pt

2nd Mariana Martins
Departamento de Engenharia Informática
ISEP
Porto, Portugal
1230679@isep.ipp.pt

3rd Samara Miranda
Departamento de Engenharia Informática
ISEP
Porto, Portugal
1230432@isep.ipp.pt

Abstract—A crescente eletrificação dos transportes e a necessidade de otimizar a utilização da infraestrutura elétrica existente tornam essencial a previsão do nível de ocupação dos Postos de Transformação de Distribuição (PTD). Após uma primeira fase de análise estatística ao nível do concelho, desenvolvida no Trabalho Prático 1, este estudo evolui para uma abordagem ao nível individual dos PTDs recorrendo a técnicas de Aprendizagem Automática. O objetivo consiste em classificar o nível de utilização da rede elétrica em três categorias de ocupação — baixo, médio e alto — utilizando variáveis relacionadas com a infraestrutura elétrica, características da iluminação pública e indicadores de eficiência energética.

Foram aplicadas técnicas de pré-processamento, seleção de atributos, balanceamento de classes através do algoritmo SMOTE e validação cruzada k-fold. Foram desenvolvidos e comparados modelos baseados em K-Nearest Neighbors (KNN), Support Vector Machines (SVM) e Árvores de Decisão, avaliando-se o seu desempenho através das métricas Accuracy, Precision, Recall e F1-Score. Adicionalmente, foram analisadas curvas de aprendizagem para identificação de fenómenos de overfitting e underfitting. Os resultados permitem identificar o modelo mais adequado para apoiar decisões relacionadas com a gestão da capacidade da rede elétrica e a integração de novas cargas associadas à mobilidade elétrica.

Index Terms—Machine Learning, Classificação, Support Vector Machines, K-Nearest Neighbors, Árvores de Decisão, SMOTE, Redes Elétricas, Postos de Transformação, Mobilidade Elétrica.

I. INTRODUÇÃO

A transição energética europeia e a crescente adoção de veículos elétricos têm aumentado a pressão sobre as infraestruturas de distribuição de energia. A capacidade disponível nos Postos de Transformação de Distribuição (PTD) assume um papel fundamental na expansão sustentável da mobilidade

elétrica, tornando necessária a existência de ferramentas que permitam antecipar situações de saturação da rede.

No Trabalho Prático 1 foi realizada uma análise estatística exploratória ao nível do concelho, permitindo identificar relações entre a capacidade instalada, a iluminação pública e os níveis médios de ocupação da rede. Contudo, os resultados obtidos evidenciaram limitações na capacidade explicativa dos modelos lineares desenvolvidos, motivando uma abordagem mais detalhada ao nível individual dos PTDs.

Neste contexto, o Trabalho Prático 2 procura aplicar técnicas de Aprendizagem Automática para prever o nível de utilização da rede elétrica. Em vez de estimar diretamente uma variável contínua, o problema foi formulado como uma tarefa de classificação multiclasse, permitindo categorizar cada PTD segundo o seu grau de ocupação.

Um dos principais desafios identificados durante a análise exploratória foi o desequilíbrio entre as classes resultantes da discretização da variável de utilização da rede. Para mitigar este problema, foram utilizadas técnicas de balanceamento sintético, nomeadamente o Synthetic Minority Over-sampling Technique (SMOTE), de forma a melhorar a capacidade de generalização dos modelos.

Foram avaliados diferentes algoritmos de classificação amplamente utilizados na literatura, incluindo K-Nearest Neighbors (KNN), Support Vector Machines (SVM) e Árvores de Decisão. O desempenho dos modelos foi analisado através de validação cruzada e métricas clássicas de classificação, permitindo identificar as abordagens mais adequadas para o problema em estudo.

II. OBJETIVOS

Os principais objetivos deste trabalho são:

- Realizar a exploração e preparação dos dados disponibilizados pela e-REDES ao nível individual dos PTDs;

- Construir uma variável categórica representativa do nível de utilização da rede elétrica;
- Aplicar técnicas de pré-processamento e engenharia de atributos adequadas ao contexto dos dados;
- Mitigar os efeitos do desequilíbrio de classes através de técnicas de reamostragem;
- Desenvolver modelos de classificação utilizando KNN, SVM e Árvores de Decisão;
- Avaliar e comparar o desempenho dos modelos através de Accuracy, Precision, Recall e F1-Score;
- Analisar as curvas de aprendizagem de forma a identificar fenómenos de overfitting e underfitting;
- Identificar limitações dos modelos e propor estratégias de melhoria para trabalhos futuros.

III. METODOLOGIA

A metodologia seguida neste trabalho está organizada em cinco etapas principais: exploração dos dados, pré-processamento, construção da variável alvo, balanceamento das classes e desenvolvimento dos modelos de classificação. Todo o processo foi implementado em Python recorrendo às bibliotecas Pandas, NumPy, Scikit-Learn, Imbalanced-Learn, Matplotlib e Seaborn.

A. Dataset

Foi utilizado o conjunto de dados `PTD_level_dataset`, disponibilizado pela e-REDES, contendo aproximadamente 72 mil registos correspondentes a PTDs distribuídos por Portugal Continental. O dataset resulta da integração dos dados de iluminação pública e dos dados técnicos dos postos de transformação, permitindo associar a cada PTD informação relativa ao respetivo concelho.

Entre as variáveis disponíveis encontram-se atributos relacionados com:

- Capacidade instalada do PTD;
- Número de clientes associados;
- Potência contratada;
- Indicadores de iluminação pública;
- Rácio de ineficiência tecnológica;
- Número de luminárias;
- Número de PTDs por concelho;
- Variáveis derivadas de viabilidade energética.

A análise desenvolvida neste trabalho incide sobre a previsão do nível de utilização da rede elétrica ao nível individual do PTD.

B. Análise Exploratória dos Dados

A primeira etapa consistiu na caracterização estatística e visual do dataset.

Foram analisadas as distribuições das principais variáveis através de histogramas, estimativas de densidade (KDE) e diagramas de extremos e quartis. A análise revelou distribuições fortemente assimétricas para variáveis como capacidade instalada, folga de rede e número de clientes, evidenciando a existência de PTDs urbanos de grande dimensão que funcionam como outliers relativamente à maioria da infraestrutura.

Verificou-se igualmente que a variável `LED_Ratio` apresenta comportamento bimodal, refletindo a coexistência de concelhos totalmente modernizados e concelhos ainda dependentes de tecnologias convencionais de iluminação pública. A variável de utilização da rede revelou uma distribuição multimodal, justificando a sua discretização em classes para o problema de classificação.




Fig. 1: Distribuição Bimodal da modernização (a) e da Ocupação dos PTDs (b), justificando a discretização em três classes.

C. Pré-Processamento

O processo de preparação dos dados incluiu diversas etapas destinadas a melhorar a qualidade da informação utilizada pelos algoritmos.

Inicialmente foram removidas variáveis identificadoras e atributos sem relevância preditiva direta, nomeadamente códigos geográficos, coordenadas e representações redundantes de variáveis já disponíveis em formato numérico.

Os valores omissos presentes em atributos relacionados com potência contratada foram imputados utilizando a mediana por tipo construtivo do PTD, preservando assim as características estruturais dos diferentes grupos de equipamentos.

Variáveis com percentagens muito elevadas de valores nulos, nomeadamente atributos relacionados com geração distribuída, foram removidas da modelação devido à reduzida qualidade informativa.

As variáveis categóricas foram convertidas para formato numérico através de técnicas de codificação apropriadas e os atributos contínuos foram normalizados utilizando `StandardScaler`, garantindo comparabilidade entre escalas distintas.

D. Construção da Variável Alvo

O objetivo da classificação consiste em prever o nível de utilização da rede elétrica.

Para esse efeito, a variável contínua `Util_Decimal` foi discretizada em três classes:

- **Baixo** – PTDs com níveis reduzidos de ocupação;
- **Médio** – PTDs com ocupação intermédia;
- **Alto** – PTDs próximos dos limites de capacidade.

A discretização foi realizada utilizando quantis, permitindo obter classes aproximadamente equilibradas e evitando a concentração excessiva de observações numa única categoria. Esta abordagem reduz o enviesamento dos modelos e facilita a comparação entre algoritmos.

E. Balanceamento das Classes

Apesar da discretização baseada em quantis produzir distribuições mais equilibradas, verificou-se a existência de diferenças na frequência relativa das classes após a divisão dos dados para treino e teste. Para mitigar este problema foi utilizada a técnica *Synthetic Minority Over-sampling Technique* (SMOTE). Este algoritmo gera observações sintéticas para as classes minoritárias através da interpolação entre exemplos vizinhos, aumentando a representatividade das categorias menos frequentes sem replicar diretamente observações existentes. A aplicação do SMOTE foi realizada exclusivamente sobre os conjuntos de treino, evitando fugas de informação (*data leakage*) para os conjuntos de validação.

F. Modelos de Classificação

Foram desenvolvidos três modelos de classificação representativos de diferentes paradigmas de Aprendizagem Automática.

1) *K-Nearest Neighbors (KNN)*: O algoritmo KNN classifica cada observação com base nas classes predominantes dos seus vizinhos mais próximos no espaço das características. O parâmetro k foi otimizado experimentalmente recorrendo a validação cruzada.

2) *Support Vector Machine (SVM)*: As Support Vector Machines procuram construir hiperplanos que maximizem a separação entre classes. Foram avaliadas diferentes funções kernel, selecionando-se a configuração que apresentou melhor desempenho médio durante o processo de validação.

3) *Árvores de Decisão*: As Árvores de Decisão realizam sucessivas divisões do espaço de atributos com o objetivo de maximizar a pureza das classes em cada nó. Para reduzir o risco de sobreajuste foram avaliados parâmetros relacionados com profundidade máxima e número mínimo de observações por folha.

G. Validação Experimental

Todos os modelos foram avaliados através de validação cruzada k -fold, garantindo uma estimativa robusta da capacidade de generalização.

As métricas utilizadas foram:

- Accuracy;
- Precision;
- Recall;
- F1-Score.

Adicionalmente, foram construídas curvas de aprendizagem para os modelos com melhor desempenho, permitindo avaliar a evolução simultânea dos resultados de treino e validação e identificar possíveis fenómenos de overfitting ou underfitting.

IV. RESULTADOS E DISCUSSÃO

Nesta secção são apresentados e discutidos os resultados obtidos pelos modelos de classificação desenvolvidos para prever o nível de utilização da rede elétrica (*baixo*, *médio* e *alto*). A avaliação foi realizada através de validação cruzada k -fold recorrendo às métricas Accuracy, Precision, Recall e F1-Score.

A. Comparação Global dos Modelos

A Tabela I apresenta os resultados médios obtidos pelos diferentes algoritmos.

TABLE I: Desempenho global dos modelos após validação (com Random Forest)

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest (Otimizado)	0.8318	0.83	0.83	0.83
Decision Tree ($d = 10$)	0.8142	0.81	0.81	0.81
SVM (RBF)	0.7580	0.76	0.76	0.76
KNN ($k = 5$)	0.7554	0.76	0.76	0.75

A introdução do algoritmo *ensemble* Random Forest, parametrizado com 100 estimadores e profundidade controlada, elevou substancialmente a Accuracy para cerca de 83.18%, superando as abordagens de classificador único, ao gerir melhor a variância e complexidade espacial dos dados.

Os resultados mostram que a Árvore de Decisão com profundidade máxima igual a 7 apresentou o melhor desempenho global, obtendo os valores mais elevados de Accuracy e F1-Score. O SVM com kernel RBF apresentou resultados muito próximos, evidenciando uma elevada capacidade de generalização. A Rede Neuronal obteve desempenho competitivo, embora com maior variabilidade entre partições de validação. O KNN foi o modelo menos eficaz, apresentando os valores mais baixos em todas as métricas avaliadas.

A diferença reduzida entre os dois melhores modelos motivou a realização de testes estatísticos adicionais. O teste t pareado aplicado às accuracies obtidas nos diferentes *folds* não revelou diferenças estatisticamente significativas ao nível de significância de 5%, indicando que a superioridade observada da Árvore de Decisão face à Rede Neuronal não pode ser considerada conclusiva do ponto de vista estatístico.

B. Desempenho por Classe

A análise das métricas por classe permitiu compreender melhor o comportamento dos modelos perante o desequilíbrio existente no conjunto de dados.

Verificou-se que a classe *baixo*, correspondente aos PTDs com menor ocupação da rede, foi sistematicamente a classe mais fácil de identificar. Esta categoria representa aproximadamente metade das observações disponíveis, proporcionando aos algoritmos uma quantidade significativamente superior de exemplos para aprendizagem. Consequentemente, os valores de Recall observados para esta classe situaram-se tipicamente entre 0.87 e 0.90.

Em contraste, a classe *médio* revelou-se a mais difícil de classificar. Os PTDs desta categoria apresentam características intermédias que partilham semelhanças tanto com os elementos classificados como *baixo* como com os classificados como *alto*. Esta sobreposição conduz a fronteiras de decisão menos definidas e traduz-se em valores de Recall significativamente inferiores.

A classe *alto* apresentou desempenho intermédio. Os modelos mostraram-se relativamente conservadores na atribuição desta categoria, produzindo valores de Precision superiores aos

valores de Recall. Tal comportamento sugere que os classificadores preferem evitar falsos alarmes de saturação da rede, embora isso implique a perda de alguns casos efetivamente pertencentes à classe *alto*.




Fig. 2: Matriz de Confusão do modelo Random Forest, demonstrando o desafio em separar as classes adjacentes ‘baixo’ e ‘medio’.

C. Impacto do Balanceamento com SMOTE

Um dos principais desafios identificados durante o desenvolvimento dos modelos foi o desequilíbrio entre classes. Embora a discretização por quantis tenha contribuído para reduzir este problema, continuaram a existir diferenças relevantes na representatividade das categorias após a divisão dos dados.

A utilização do algoritmo SMOTE revelou-se particularmente importante para melhorar a capacidade dos classificadores em reconhecer exemplos pertencentes às classes minoritárias. A geração de observações sintéticas permitiu aumentar a diversidade dos exemplos de treino sem replicar diretamente registos existentes, reduzindo o enviesamento para a classe maioritária.

O principal benefício observou-se ao nível do Recall das classes *médio* e *alto*, uma vez que os modelos passaram a identificar uma proporção superior de casos efetivamente pertencentes a estas categorias. Sem a aplicação do SMOTE, os algoritmos tenderiam a privilegiar excessivamente a classe *baixo*, produzindo classificadores aparentemente precisos mas pouco úteis para identificar situações de maior ocupação da rede.

D. Importância das Variáveis

A análise de importância de atributos realizada para a Árvore de Decisão revelou que as variáveis mais relevantes para a classificação foram:

- Cap_per_Cliente;
- PContratada_per_Cliente;
- Cap_PTD_kVA;
- Pot_Contratada_kVA;
- N_Clientes.

A variável Cap_per_Cliente destacou-se claramente como o atributo mais informativo, concentrando mais de 70% da importância total do modelo. Este resultado sugere que a relação entre capacidade disponível e número de clientes constitui o principal indicador do nível de utilização da rede.

Por outro lado, as variáveis associadas à iluminação pública apresentaram contributos reduzidos para a classificação. Tal resultado é consistente com a natureza agregada destes atributos ao nível do concelho, que não refletem adequadamente as diferenças individuais entre PTDs.

E. Curvas de Aprendizagem

As curvas de aprendizagem permitiram analisar a eficiência do processo de treino e a capacidade de generalização dos modelos.

A Árvore de Decisão apresentou um padrão característico de ligeiro sobreajuste (*overfitting*). A Accuracy de treino manteve-se consistentemente superior à Accuracy de validação, embora a diferença entre ambas fosse relativamente reduzida. Este comportamento indica que o modelo aprende alguns padrões específicos do conjunto de treino, mas continua a generalizar adequadamente para dados não observados.

Por sua vez, o KNN evidenciou sinais de subajuste (*underfitting*). Apesar de apresentar resultados razoáveis no conjunto de treino, a curva de validação permaneceu significativamente abaixo da curva de treino e continuou a crescer à medida que mais exemplos eram disponibilizados. Este comportamento sugere que o modelo ainda não consegue capturar integralmente a estrutura dos dados.

O SVM demonstrou um comportamento mais equilibrado, apresentando boa capacidade de generalização e reduzida diferença entre desempenho de treino e validação. A Rede Neuronal revelou igualmente estabilidade durante o treino, não tendo sido observados sinais evidentes de sobreajuste graças à utilização de mecanismos de regularização e *early stopping*.

De forma global, os resultados das curvas de aprendizagem indicam que os modelos atingiram um patamar próximo do limite informativo disponibilizado pelas variáveis atualmente existentes no dataset. Consequentemente, melhorias substanciais poderão depender mais da introdução de novos atributos explicativos do que simplesmente do aumento da dimensão da amostra.




Fig. 3: Curvas de Aprendizagem. É visível que as Árvores simples sofrem de um rápido *overfitting* (desvio entre treino e validação), enquanto modelos otimizados estabilizam precocemente.

V. LIMITAÇÕES E TRABALHO FUTURO

Apesar dos resultados obtidos serem encorajadores, existem diversas limitações que condicionam o desempenho dos modelos desenvolvidos.

Uma das principais limitações está relacionada com a própria variável alvo. O nível de utilização da rede deriva de uma variável originalmente discretizada em poucos intervalos, o que reduz a granularidade da informação disponível e dificulta a separação entre classes adjacentes.

Outra limitação importante resulta da natureza agregada de várias variáveis associadas à iluminação pública. Atribuir os mesmos indicadores municipais a todos os PTDs de um concelho reduz a capacidade discriminativa destas características e limita a sua utilidade para classificação ao nível individual.

Adicionalmente, os modelos foram desenvolvidos assumindo um comportamento global comum para todos os PTDs nacionais. Contudo, existem diferenças estruturais significativas entre contextos urbanos e rurais, nomeadamente ao nível da densidade populacional, do perfil de consumo e da capacidade instalada.

Como trabalho futuro, propõem-se as seguintes estratégias:

- Realização de uma otimização mais detalhada dos hiperparâmetros dos modelos, explorando sistematicamente parâmetros como C e γ no SVM e diferentes estratégias de ponderação (*weights*) no KNN;
- Aplicação de modelos *ensemble* mais avançados, nomeadamente Random Forest e XGBoost, capazes de reduzir variância e melhorar a robustez da classificação;
- Inclusão de novas variáveis relacionadas com geração distribuída, produção fotovoltaica e perfis reais de carregamento de veículos elétricos;
- Desenvolvimento de modelos específicos para diferentes categorias de PTD, recorrendo à estratificação segundo o Tipo Construtivo ou à separação explícita entre contextos urbanos e rurais;
- Utilização de informação georreferenciada que permita associar de forma mais precisa a infraestrutura de iluminação pública aos respetivos postos de transformação.

Estas estratégias poderão contribuir para melhorar a capacidade de generalização dos modelos e aumentar a sua aplicabilidade em cenários reais de planeamento energético.

VI. CONCLUSÃO

Este trabalho demonstrou o potencial das técnicas de Aprendizagem Automática na previsão do nível de utilização da rede elétrica ao nível dos Postos de Transformação de Distribuição.

Entre os modelos avaliados, a Árvore de Decisão apresentou o melhor desempenho global, alcançando aproximadamente 70% de Accuracy e os valores mais elevados de F1-Score. O SVM obteve resultados muito próximos, enquanto o KNN revelou limitações na capacidade de generalização. Os testes estatísticos realizados indicaram, contudo, que as diferenças entre os melhores modelos não são estatisticamente significativas ao nível de confiança considerado.

A análise das importâncias das variáveis evidenciou que os principais fatores explicativos da ocupação da rede estão relacionados com a capacidade disponível por cliente e com a potência contratada. Em contrapartida, os indicadores associados à iluminação pública revelaram impacto reduzido na classificação dos PTDs individuais.

Os resultados sugerem ainda que a eficiência energética associada à modernização da iluminação pública, embora relevante numa perspetiva global de sustentabilidade, apresenta um efeito limitado quando analisada isoladamente ao nível de cada PTD. Tal conclusão reforça a necessidade de incorporar informação adicional relacionada com padrões reais de consumo, geração distribuída e mobilidade elétrica.

Em síntese, os modelos desenvolvidos constituem uma base promissora para apoiar processos de planeamento e gestão da infraestrutura elétrica, podendo contribuir para decisões mais informadas no contexto da transição energética e da expansão da mobilidade elétrica.

AGRADECIMENTOS

Este trabalho foi desenvolvido com o apoio de ferramentas de Inteligência Artificial Generativa para apoio à programação, análise de dados e revisão textual. A utilização destas ferramentas foi efetuada de forma ética e transparente, mantendo sempre a validação crítica dos resultados obtidos pelos autores e respeitando as orientações institucionais relativas ao uso de IA em contexto académico.

REFERENCES

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] T. M. Mitchell, *Machine Learning*. McGraw-Hill, 1997.
- [3] G. James, D. Witten, T. Hastie and R. Tibshirani, *An Introduction to Statistical Learning*, 2nd ed., Springer, 2021.
- [4] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter*, 3rd ed., O'Reilly Media, 2022.
- [5] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*. MIT Press, 2016.
- [6] N. V. Chawla, K. W. Bowyer, L. O. Hall and W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [7] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [8] e-REDES, "Portal de Dados Abertos," [Online]. Available: <https://www.e-redes.pt>